# Consistent Instance False Positive Improves Fairness in Face Recognition

Xu, X., Huang, Y., Shen, P., Li, S., Li, J., Huang, F., Li, Y., and Cui, Z., Consistent Instance False Positive Improves Fairness in Face Recognition, Proc. of CVPR 2021, pp. 578-586.

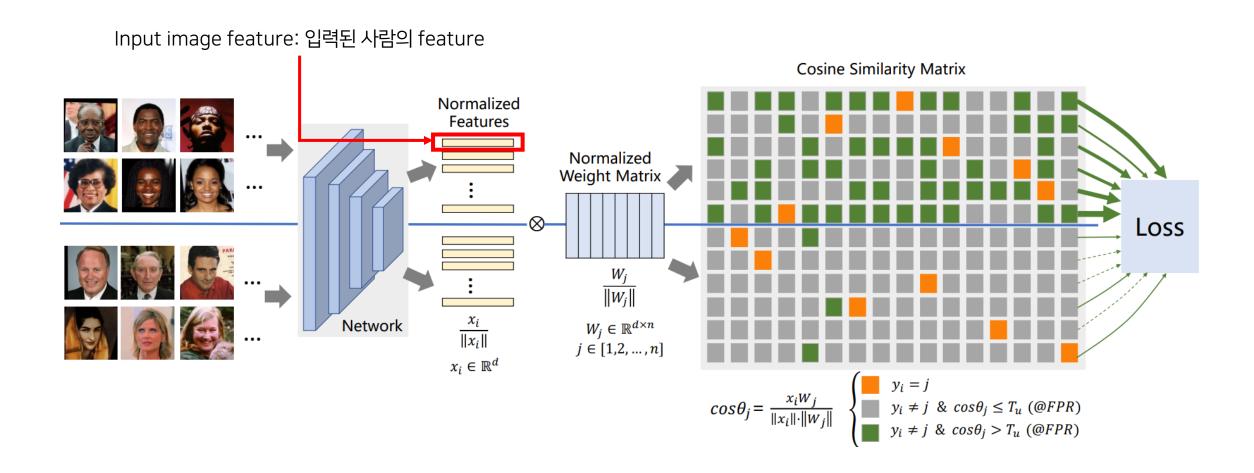
	T	F
P	TP 동일한 사람인데 허용한 경우(정답)	FP 다른 사람인데 허용한 경우(오답)
N	TN 다른 사람인데 거부한 경우(정답)	FN 동일한 사람인데 거부한 경우(오답)

# 목차

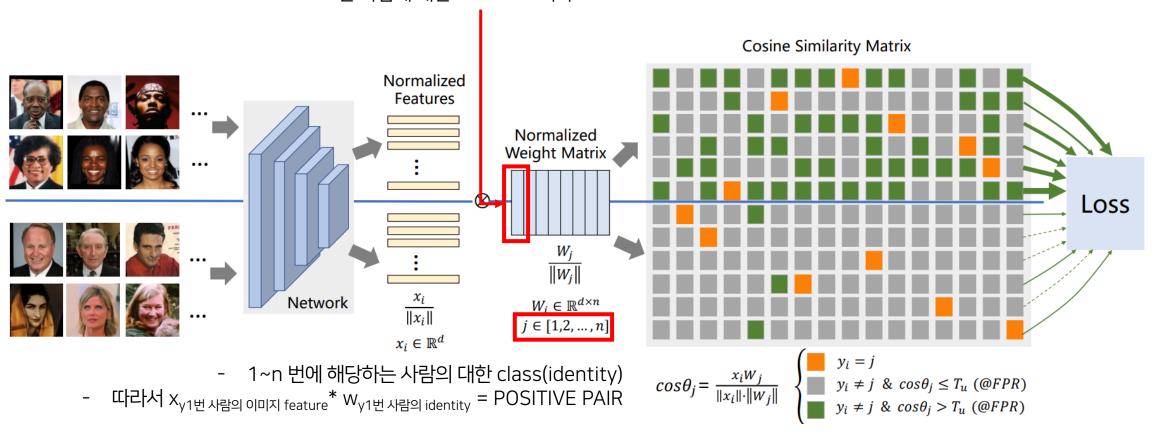
- 00. Abstract
- 01. Introduction
- 02. Related Work
- 03. Proposed Approach
- 04. Experiments
- 05. Conclusion

해결해야 하는 문제	얼굴 인식 시스템에서 인구 <del>통</del> 계학적 편향
기존 연구의 한계	인구통계학적 주석에 의존하기 때문에 실제 시나리오에서 사용 불가 ▶ 특정 인구 그룹을 위해 설계되었으므로 일반적이지 못함
해결 방법	Instance False Positive Rate(FPR)의 일관성을 높여 얼굴 인식의 편향을 완화하는 Penalty Loss 제안 ▶ 인구 통계학적 그룹 간의 편향 완화
저자코드	https://github.com/Tencent/TFace

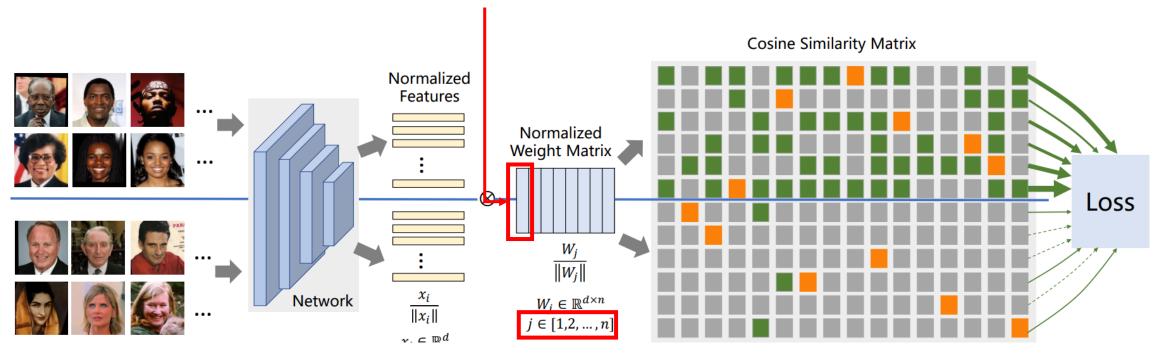
# Instance FPR이란?



Given a weight matrix W that each column corresponds to one identity(본 논문 발췌) 한 사람에 대한 IDENTITY이자 class

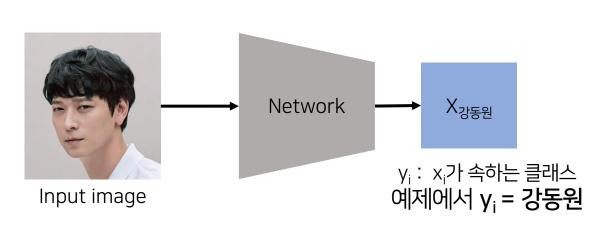


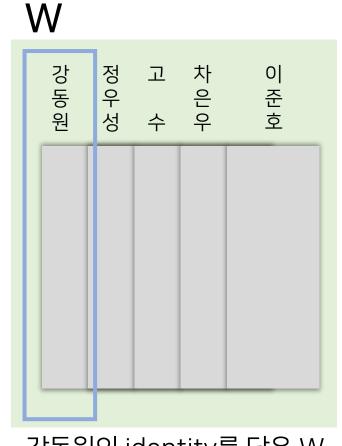
#### 한 사람에 대한 IDENTITY이자 class



- 1~n 번에 해당하는 사람의 대한 class(identity)
- 따라서  $x_{y1번 \text{ 사람의 OIDN feature}} * w_{y1번 \text{ 사람의 identity}} = POSITIVE PAIR$

$$cos heta_j = rac{x_i W_j}{\|x_i\| \cdot \|W_j\|}$$
  $\begin{cases} y_i = j \text{ # Positive pair; } \text{ 입력한 사람과 동일한 identity의 유사성} \\ y_i \neq j \text{ & } cos heta_j \leq T_u \text{ (@FPR)} \text{ # Negative pair; } \text{ 입력한 사람과 다른 identity의 유사성이 임계치보다 작거나 같을 때 } \\ y_i \neq j \text{ & } cos heta_j > T_u \text{ (@FPR)} \text{ # Negative pair; } \text{ 입력한 사람과 다른 identity의 유사성이 임계치보다 클 때 # 임계치 이상의 유사도를 갖는 non-target similarities} \end{cases}$ 

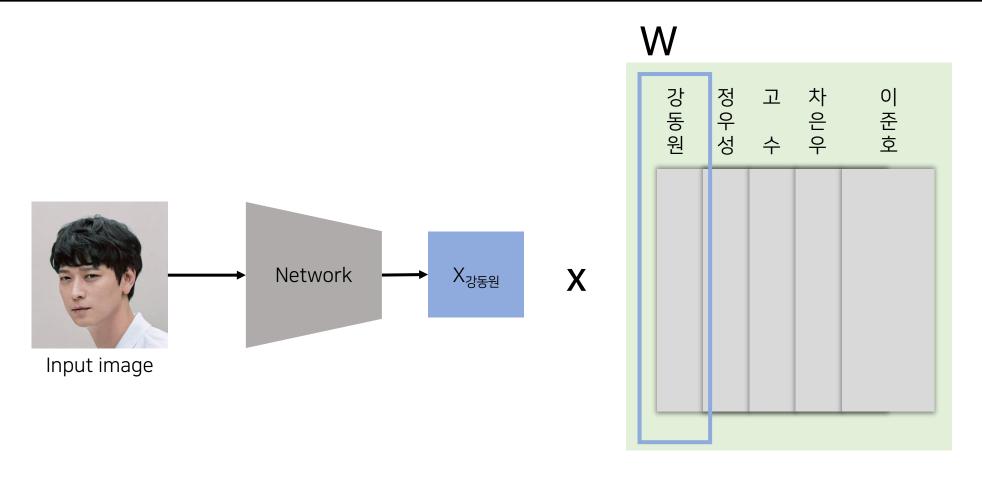




강동원의 identity를 담은  $W_{vi}$ 

정리

y<sub>i</sub>: y<sub>i</sub> class

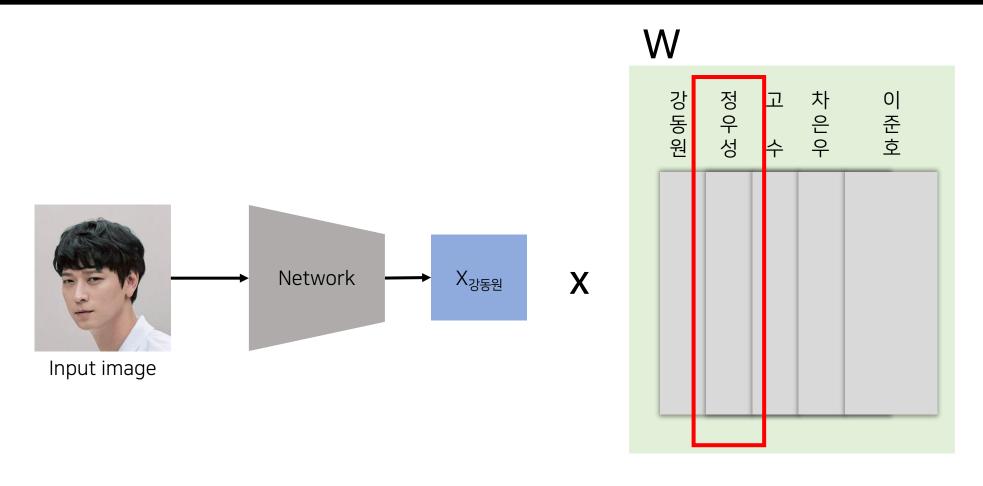




Positive pair!!

정리

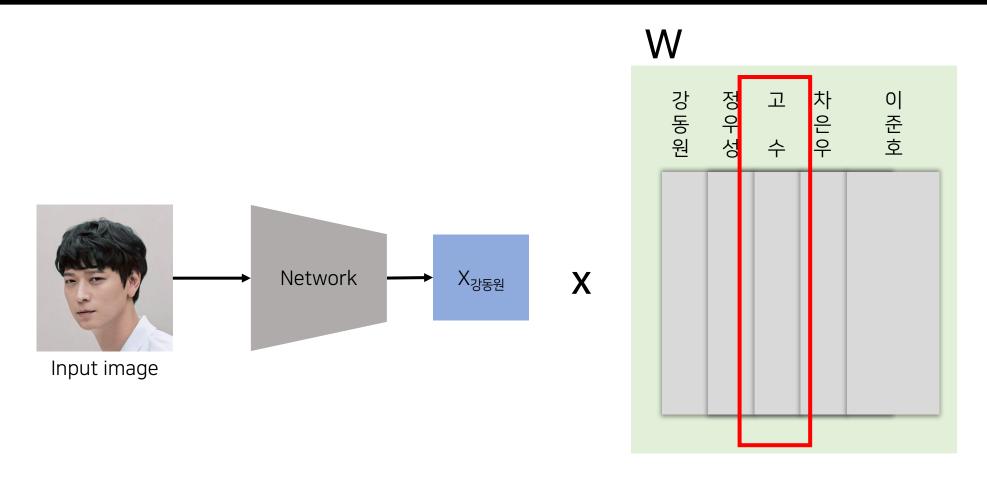
y<sub>i</sub>: y<sub>i</sub> class





정리

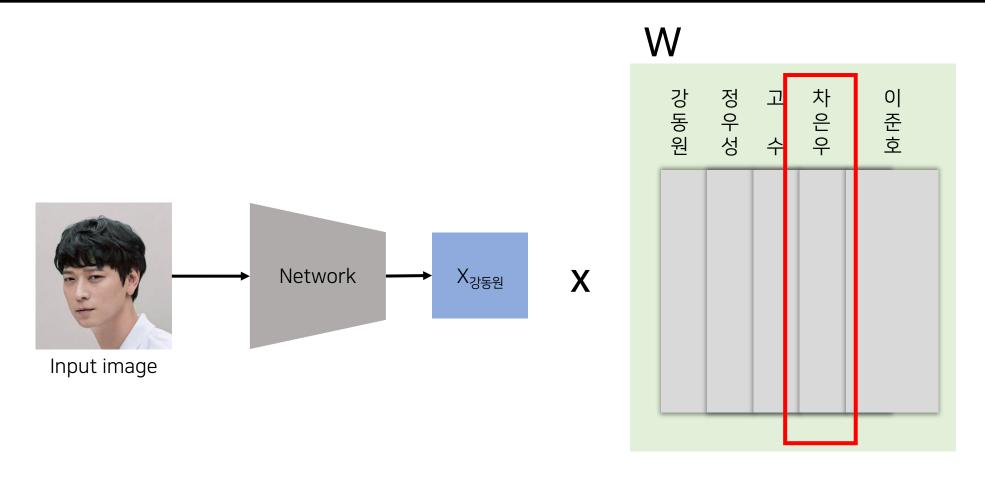
y<sub>i</sub>: y<sub>i</sub> class





정리

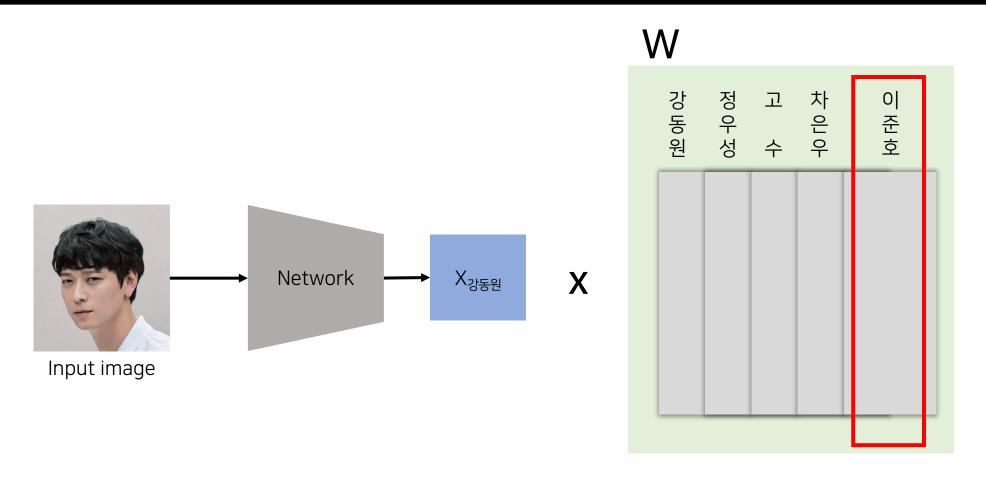
y<sub>i</sub>: y<sub>i</sub> class





정리

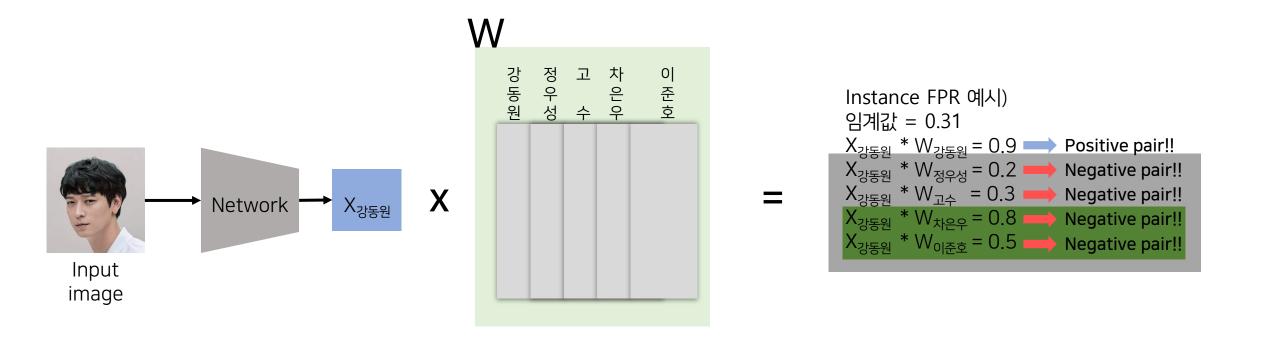
y<sub>i</sub>: y<sub>i</sub> class





정리

y<sub>i</sub>: y<sub>i</sub> class



Instance FPR = 
$$\frac{임계치 이상의 유사도를 갖는 non-target similarities 수}{non-target similarities 수} = \frac{2}{4}$$

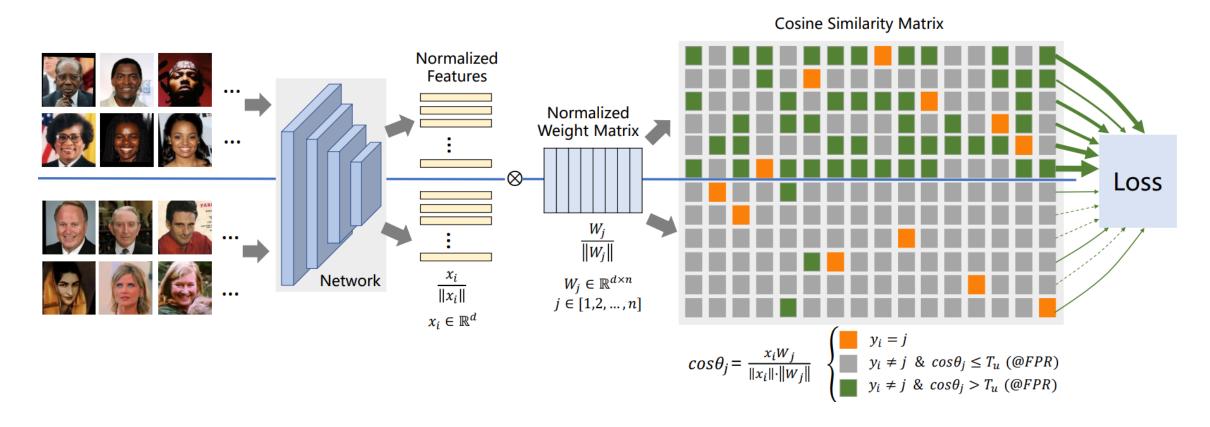
정리

y<sub>i</sub>: y<sub>i</sub> class

x<sub>i</sub>: class y<sub>i</sub>에 속하는 i번째 sample의 deep feature

target similarities  $\uparrow$  = Positive pair non-target similarities  $\uparrow$  = Negative pair

- 다르게 쓰는 이유: 전체 Positive/Negative pair를 보는 것이 아닌 미니 배치 사이즈만큼 보기 때문에 전체 positive/negative pair와 구별해줄 필요가 있어서 다르게 쓰는 것이 아닌지 추측



### 01. Introduction

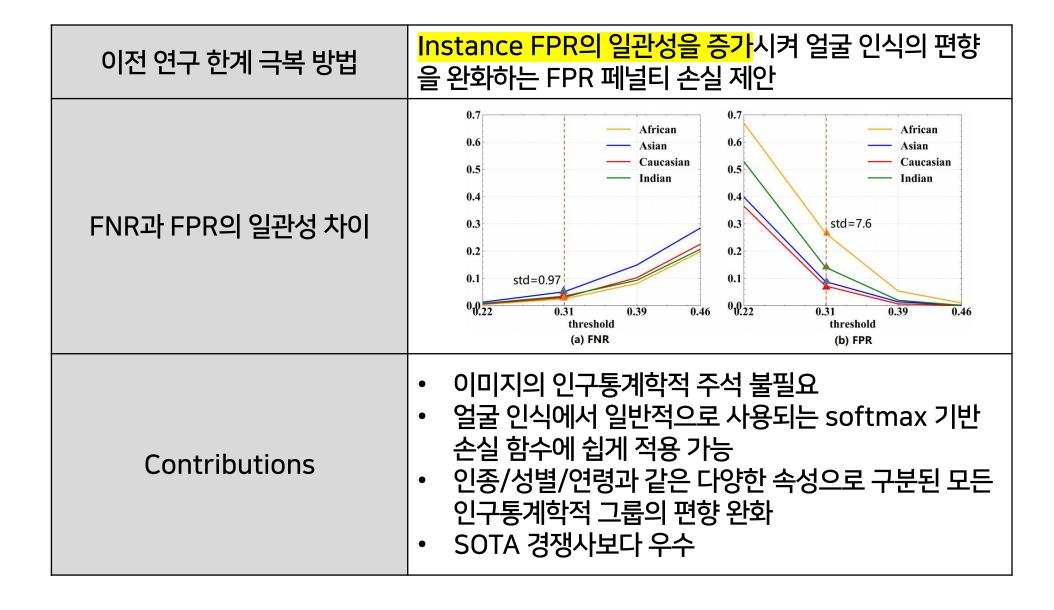
#### 01. Introduction





균형 여부 관계 없이 편향을 완화할 수 있는 알고리즘 필요

#### 01. Introduction



#### 02. Related Work

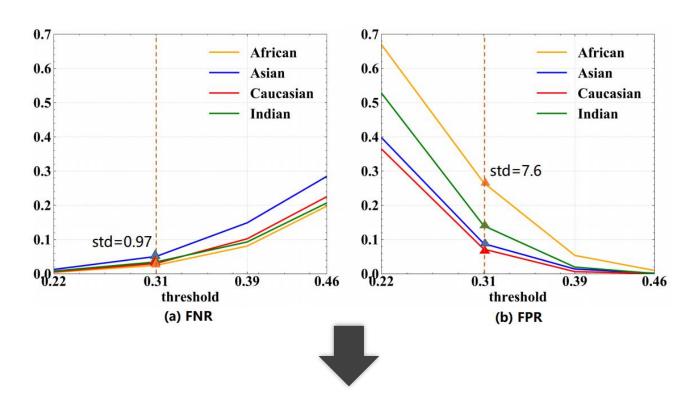
#### 02. Related Work

Loss Functions	성능이 향상되지만 편향 고려 불가	
Dataset	DiF(Diversity in Faces)	100만 개의 얼굴 이미지에 대한 주석 제공
	RFW(Racial faces in-the-wild)	인종 편견 연구
	BUPT-balanced	인종에 대해 균형 잡힌 dataset 도입
	BUPT-Globalface	세계 인구 실제 분포 공개
	BFW	8개의 인구 통계학적 그룹 포함
Algorithm	<ul> <li>Deep Information Maximization Adaptation 네트워크</li> <li>편향 제거 적대 네트워크: 4개의 특정 분류기 사용자</li> </ul>	

# 03. Proposed Approach

# 03-1. Demographic Bias

- FPR vs Bias
  - 인구통계학적 그룹마다 FNR에 비해 FPR의 일관성이 떨어짐



인구통계 전반에 걸쳐 FNR보다 FPR에서 높은 일관성 달성 필수

#### 기호

FPR 
$$\gamma^+=rac{\sum_{i=1}^{N^-}\mathbb{1}(S^-[i]>T_u)}{N^-},$$
  $N^-$  # 전체적인 Negative pair 수  $N^+$  위계치를 넘는 유사도를 갖는 Positive pair 수  $N^+$   $N^+$  # 전체적인 Positive pair 수  $N^+$  # 전체적인 Positive pair 수  $N^+$  # 전체적인 Positive pair 수

#### <u>그룹 내 FNR, FPR</u>

$$\gamma_{g}^{+} = \frac{\sum_{i=1}^{i=1} \mathbb{I}(S_{g}[i] > T_{u})}{N_{g}^{-}},$$

$$\gamma_{g}^{-} = \frac{\sum_{i=1}^{N_{g}^{+}} \mathbb{I}(S_{g}^{+}[i] < T_{u})}{N_{g}^{+}},$$

Softmax Loss Function

- 개별가중치는  $l_2$  norm에 의해  $||W_i|| = 1$ ,  $b_i = 0$ 로 설정
- X<sub>i</sub> deep feature --정규화--> s

$$\mathcal{L} = -\log \frac{e^{W_{y_i} x_i + b_{y_i}}}{\sum_{j=1}^n e^{W_j x_i + b_j}}, \quad \blacksquare$$



#### Softmax Loss Function

- 개별가중치는  $l_2$  norm에 의해  $||W_i|| = 1$ ,  $b_i = 0$ 로 설정
- X<sub>i</sub> deep feature --정규화--> s

$$\mathcal{L} = -\log \frac{e^{W_{y_i} x_i + b_{y_i}}}{\sum_{j=1}^n e^{W_j x_i + b_j}}, \quad \blacktriangleright \quad \mathcal{L} = -\log \frac{e^{s(\cos \theta_{y_i})}}{e^{s(\cos \theta_{y_i})} + \sum_{j \neq y_i}^n e^{s(\cos \theta_j)}}.$$

#### Softmax Loss Function

- 개별가중치는  $l_2$  norm에 의해  $||W_i|| = 1$ ,  $b_i = 0$ 로 설정
- X<sub>i</sub> deep feature --정규화--> s

$$\mathcal{L} = -\log \frac{e^{W_{y_i} x_i + b_{y_i}}}{\sum_{j=1}^n e^{W_j x_i + b_j}}, \qquad \qquad \mathcal{L} = -\log \frac{e^{s(\cos \theta_{y_i})}}{e^{s(\cos \theta_{y_i})} + \sum_{j \neq y_i}^n e^{s(\cos \theta_j)}}$$

• Positive pair와 Negative pair 분리

#### Softmax Loss Function

- 개별가중치는  $l_2$  norm에 의해  $||W_i|| = 1$ ,  $b_i = 0$ 로 설정
- X<sub>i</sub> deep feature --정규화--> s

$$\mathcal{L} = -\log \frac{e^{W_{y_i} x_i + b_{y_i}}}{\sum_{j=1}^n e^{W_j x_i + b_j}}, \qquad \qquad \mathcal{L} = -\log \frac{e^{s(\cos \theta_{y_i})}}{e^{s(\cos \theta_{y_i})} + \sum_{j \neq y_i}^n e^{s(\cos \theta_j)}}$$

• Positive pair와 Negative pair 분리

- $G(\cos \theta_{y_i}) = \cos(\theta_{y_i} + m)$ : inter-class similarity 강조
- $H(\cos \theta_I)$ : mining-based loss functions, intra-class의 혼란을 감소





Figure 3. The **Triplet Loss** minimizes the distance between an *anchor* and a *positive*, both of which have the same identity, and maximizes the distance between the *anchor* and a *negative* of a different identity.

#### Softmax Loss Function

- 개별가중치는  $l_2$  norm에 의해  $||W_i|| = 1$ ,  $b_i = 0$ 로 설정
- X<sub>i</sub> deep feature --정규화--> s

$$\mathcal{L} = -\log \frac{e^{W_{y_i} x_i + b_{y_i}}}{\sum_{j=1}^n e^{W_j x_i + b_j}}, \quad \blacktriangleright \quad \mathcal{L} = -\log \frac{e^{s(\cos \theta_{y_i})}}{e^{s(\cos \theta_{y_i})} + \sum_{j \neq y_i}^n e^{s(\cos \theta_j)}}.$$

- $G(\cos \theta_{v_i}) = \cos(\theta_{v_i} + m)$ : inter-class similarity 강조
- $H(\cos \theta_I)$ : mining-based loss functions, intra-class의 혼란을 감소

$$\mathcal{L} = -\log \frac{e^{s \cdot G(\cos \theta_{y_i})}}{e^{s \cdot G(\cos \theta_{y_i})} + \sum_{j \neq y_i}^{n} e^{s \cdot H(\cos \theta_j)}},$$

#### Extra Penalty on the FPR of Instance

Since the  $y_i$ -th column of the weight W usually could be regarded as a representative of the  $y_i$ -th class, for the i-th instance belonging to class  $y_i$ , the target logit  $\cos\theta_{y_i}$  could be considered as the similarity of a positive pair, while the non-target logits  $\cos\theta_j$ ,  $j\neq y_i$  could be considered as the similarities of negative pairs.

Instance FPR

$$\gamma_i^+ = rac{\sum_{j=1, j 
eq y_i}^n \mathbb{1}(\cos \theta_j > T_u)}{n-1}, = rac{ ext{임계치 이상의 유사도를 갖는 non-target similarities 수}}{non-target similarities 수}$$

#### Extra Penalty on the FPR of Instance

Since the y<sub>i</sub>-th column of the weight W usually could be regarded as a representative of the y<sub>i</sub>-th class, for the i-th instance belonging to class y<sub>i</sub>, the target logit  $\cos \theta_{y_i}$  could be considered as the similarity of a positive pair, while the non-target logits  $\cos \theta_i$ , j  $\neq$  yi could be considered as the similarities of negative pairs.

Instance FPR

$$\gamma_i^+ = rac{\sum_{j=1, j 
eq y_i}^n \mathbb{1}(\cos \theta_j > T_u)}{n-1}, = \frac{$$
임계치이상의 유사도를 갖는 non-target similarities 수 non-target similarities 수

#### Loss function

$$\mathcal{L} = -\log \frac{e^{s \cdot G(\cos \theta_{y_i})}}{e^{s \cdot G(\cos \theta_{y_i})} + \sum_{j \neq y_i}^{n} e^{s \cdot \left(\cos \theta_j + \alpha \frac{\gamma_i^+}{\gamma_u^+}\right)}}.$$

 $\mathcal{L} = -\log \frac{e^{s \cdot G(\cos \theta_{y_i})}}{e^{s \cdot G(\cos \theta_{y_i})} + \sum_{j \neq y_i}^{n} e^{s \cdot \left(\cos \theta_j + \alpha \frac{\gamma_i^+}{\gamma_u^+}\right)}}.$  Instance FPR 일관성 있게 하려면(= 모든  $\gamma_i^+$ 이  $\gamma_u^+$ 에 가깝게 만들기 위해)  $\alpha \frac{\gamma_i^+}{\gamma_u^+}$  추가  $e^{s \cdot G(\cos \theta_{y_i})} + \sum_{j \neq y_i}^{n} e^{s \cdot \left(\cos \theta_j + \alpha \frac{\gamma_i^+}{\gamma_u^+}\right)}$ .  $e^{s \cdot \alpha \frac{\gamma_i^+}{\gamma_u^+}} > 1$  이므로  $\gamma_i^+$ 가 커질수록 Loss가 커지는 불평등

#### Extra Penalty on the FPR of Instance

Since the y<sub>i</sub>-th column of the weight W usually could be regarded as a representative of the y<sub>i</sub>-th class, for the i-th instance belonging to class y<sub>i</sub>, the target logit  $\cos \theta_{v_i}$  could be considered as the similarity of a positive pair, while the non-target logits  $\cos \theta_i$ , j  $\neq$  yi could be considered as the similarities of negative pairs.

#### Instance FPR

$$\gamma_i^+ = rac{\sum_{j=1, j 
eq y_i}^n \mathbb{1}(\cos \theta_j > T_u)}{n-1}, = \frac{$$
임계치이상의 유사도를 갖는 non-target similarities 수 non-target similarities 수

#### Loss function

$$\mathcal{L} = -\log \frac{e^{s \cdot G(\cos \theta_{y_i})}}{e^{s \cdot G(\cos \theta_{y_i})} + \sum_{j \neq y_i}^{n} e^{s \cdot \left(\cos \theta_j + \alpha \frac{\gamma_i^+}{\gamma_u^+}\right)}}$$

 $\mathcal{L} = -\log \frac{e^{s \cdot G(\cos \theta_{y_i})}}{e^{s \cdot G(\cos \theta_{y_i})} + \sum_{j \neq y_i}^{n} e^{s \cdot \left(\cos \theta_j + \frac{\gamma_i^+}{\gamma_u^+}\right)}}.$  Instance FPR 일관성 있게 하려면(= 모든  $\gamma_i^+$ 이  $\gamma_u^+$ 에 가깝게 만들기 위해)  $\alpha \frac{\gamma_i^+}{\gamma_u^+}$  추가  $e^{s \alpha \frac{\gamma_i^+}{\gamma_u^+}} > 1$  이므로  $\gamma_i^+$ 가 커질수록 Loss가 커지는 불평등

#### Instance FPR

$$\bar{\gamma}_i^+ = \frac{\sum_{j=1, j \neq y_i}^n \mathbb{1}(\cos \theta_j > T_u) \cdot F(\cos \theta_j)}{n-1}. \qquad F(z) = z^p \text{ Negative p}$$

$$F(z) = z^p$$

Negative pair 중 유사도 클수록  $(\cos \theta_i)^p$  항을 추가하여 높은 가중치 부여

# Input:

# 수렴되지 않을 동안

- sample's deep feature & label y; 간 cosine 유사도

# sample 중에서 negative pair의 cosine 유사도 계산

# parameters update  $\frac{\partial \mathcal{L}_i}{\partial W_i} = \left(1 + \frac{\alpha}{\gamma_i^+} \cdot I_j \frac{\partial F}{\partial \cos \theta_i}\right) \cdot \frac{\partial \mathcal{L}_i}{\partial H_i} \cdot x_i$ ,

T.보다 작을 때는 0; TN(정답)

 $\mathcal{L} = -\log \frac{e^{s \cdot G(\cos \theta_{y_i})}}{e^{s \cdot G(\cos \theta_{y_i})} + \sum_{i \neq n}^{n} e^{s \cdot \left(\cos \theta_j + \alpha \frac{\gamma_i^+}{\gamma_u^+}\right)}}.$ 

 $\frac{\partial \mathcal{L}_i}{\partial x_i} = \frac{\partial \mathcal{L}_i}{\partial G_i} \cdot W_{y_i} + \left(1 + \frac{\alpha}{\gamma_u^+} \cdot \sum_{i \neq y_i} I_j \frac{\partial F}{\partial \cos \theta_j}\right) \cdot \frac{\partial \mathcal{L}_i}{\partial H_j} \cdot W_j,$ 

# Instance FPR 계산  $\bar{\gamma}_i^+ = \frac{\sum_{j=1, j \neq y_i}^n \mathbb{1}(\cos \theta_j > T_u) \cdot F(\cos \theta_j)}{n-1}.$ 

# 만약 cosine 유사도가 T<sub>u</sub>보다 클 때는 1; FP

# 역전파를 통한  $W_i$  계산  $\frac{\partial \mathcal{L}_i}{\partial W_{y_i}} = \frac{\partial \mathcal{L}_i}{\partial G_i} \cdot x_i,$ 

- last fully-connected layer parameters W

- embedding network parameters  $\theta$ 

- overall false positive rate  $\gamma_{i}^{+}$ 

- class number c

- learning rate  $\lambda$ 

# Loss 계산

- sample number n

#### **Algorithm 1:** FPR Penalty Loss

```
Input: The deep feature of i-th sample with its label y_i,
          cosine similarity \cos \theta_i of two vectors, last
          fully-connected layer parameters W, embedding
          network parameters \Theta, class number c, sample
          number n, learning rate \lambda, and overall false
          positive rate \gamma_u^+
iteration number k \leftarrow 0, parameter t \leftarrow 0, \gamma_u^+ \leftarrow 1e^{-4};
while not converged do
     Compute the \lceil \gamma_u^+ n(c-1) \rceil-th largest value of set
        \{\cos \theta_j \mid i \in [1, n], j \in [1, c], j \neq y_i\} as the
       temporary threshold T_u;
     if \cos(\theta_i) > T_u then
           I_i = 1;
     else
           I_i = 0;
     end
     Compute the weighted FPR \bar{\gamma}_i^+ by Eq. 11;
     Compute the loss \mathcal{L} by Eq. 10 (replace \gamma_i^+ by \bar{\gamma}_i^+);
     Compute the gradient of W_i and x_i by Eq. 12;
     Update the parameters W and \Theta by:
       W^{(k+1)} = W^{(k)} - \lambda^{(k)} \frac{\partial \mathcal{L}_i}{\partial W},
       \Theta^{(k+1)} = \Theta^{(k)} - \lambda^{(k)} \frac{\partial \check{\mathcal{L}}_i}{\partial x_i} \frac{\partial x_i}{\partial \Theta^{(k)}};
     k \leftarrow k + 1;
end
Output: W, \Theta.
```

#### Optimization

$$\frac{\partial \mathcal{L}_{i}}{\partial W_{y_{i}}} = \frac{\partial \mathcal{L}_{i}}{\partial G_{i}} \cdot x_{i}, \quad \# G_{i} = \cos \theta_{y_{i}} - m$$

$$\frac{\partial \mathcal{L}_{i}}{\partial W_{j}} = \left(1 + \frac{\alpha}{\gamma_{u}^{+}} \cdot I_{j} \frac{\partial F}{\partial \cos \theta_{j}}\right) \cdot \frac{\partial \mathcal{L}_{i}}{\partial H_{j}} \cdot x_{i}, \quad \# H_{j} = \cos \theta_{j} + \alpha \frac{\overline{\gamma}_{i}^{+}}{\gamma_{u}^{+}}$$

$$\frac{\partial \mathcal{L}_{i}}{\partial x_{i}} = \frac{\partial \mathcal{L}_{i}}{\partial G_{i}} \cdot W_{y_{i}} + \left(1 + \frac{\alpha}{\gamma_{u}^{+}} \cdot \sum_{j \neq y_{i}} I_{j} \frac{\partial F}{\partial \cos \theta_{j}}\right) \cdot \frac{\partial \mathcal{L}_{i}}{\partial H_{j}} \cdot W_{j},$$
(12)

# 04. Experiments

#### Dataset

승려	BUPT-Balancedface	<ul> <li>28000명 유명인의 이미지(130만장)</li> <li>인종 분포: 인종당 7000명</li> </ul>
훈련	BUPT-Globalface	38000명 유명인의 200장 이미지 포함     인종 분포: 세계 인구의 실제 분포와 거의 동일
	RFW	<ul> <li>4개 인종(아프리카, 아시아, 코카서스, 인도) 그룹</li> <li>각 인종 3000명의 얼굴이 약 10000장 포함</li> </ul>
테스트 BFW		<ul> <li>ID, 성별 및 인종을 포함한 더 많은 속성을 가진 균형 잡힌 얼굴 데이터 제공</li> <li>2개의 성별 &amp; 4개 인종(흑인, 백인, 아시아인, 인도 인) → 8개의 인구 통계학적 그룹</li> </ul>

Embedding network	ResNet34, ResNet50, ResNet100 채택					
Framework	Pytorch	Pytorch				
Batch size	512	512				
S	64					
m	0.35					
	BUPT-Balancedface	BUPT-Globalface				
Train	<ul> <li>Learning rate: 0.1         (20, 32, 36 epoch         에서 10으로 나눔)</li> <li>Epoch: 40</li> </ul>	<ul> <li>Learning rate: 0.1         (10, 18, 22 epoch에         서 10으로 나눔)</li> <li>Epoch: 24</li> </ul>				

	<b>.</b>	$_{oldsymbol{ ho}}s\cdot G(\cos heta_{y_i})$	
Embedding network	$\mathcal{L} = -\log \frac{1}{2}$		· · · · ·
Framework	$e^{s \cdot G(c)}$	$\frac{1}{(\cos\theta_{y_i})} + \sum_{j \neq y_i}^n e^{s \cdot H(y_i)}$	$(\cos  heta_j)$ '
Batch size	512		
S	64		
m	0.35		
	BUPT-Balancedface	BUPT-Globalface	
Train	<ul> <li>Learning rate: 0.1 (20, 32, 36 epoch 에서 10으로 나눔)</li> <li>Epoch: 40</li> </ul>	<ul> <li>Learning rate: 0.1         (10, 18, 22 epoch에         서 10으로 나눔)</li> <li>Epoch: 24</li> </ul>	

$$\frac{\partial \mathcal{L}_i}{\partial W_{y_i}} = \frac{\partial \mathcal{L}_i}{\partial G_i} \cdot x_i, \quad \# G_i = \cos \theta_{y_i} - \boxed{m}$$

Embedding network	ResN $\frac{\partial \mathcal{L}_i}{\partial W_i} = \left(1 + \frac{\alpha}{\alpha^+}\right)$	$ I_{j} \frac{\partial F}{\partial \cos \theta_{j}} \cdot \frac{\partial \mathcal{L}_{i}}{\partial H_{j}} \cdot x_{i},  \# H_{j} = \cos \theta_{j} + \alpha \frac{\overline{\gamma_{i}^{+}}}{\gamma_{u}^{+}} $ $ + \left( 1 + \frac{\alpha}{\gamma_{u}^{+}} \cdot \sum_{j \neq y_{i}} I_{j} \frac{\partial F}{\partial \cos \theta_{j}} \right) \cdot \frac{\partial \mathcal{L}_{i}}{\partial H_{j}} \cdot W_{j}, $
Framework	Pytor	$\gamma_{u}$
Batch size	$512 \frac{\partial \mathcal{L}_i}{\partial \mathcal{L}_i} = \frac{\partial \mathcal{L}_i}{\partial \mathcal{L}_i} \cdot W_{u_i}$	$+\left(1+\frac{\alpha}{1+\alpha}\cdot\sum I_{i}\frac{\partial F}{\partial F}\right)\cdot\frac{\partial\mathcal{L}_{i}}{\partial F}\cdot W_{i},$
S	$\boxed{64}  \partial x_i  \partial G_i  g_i$	$\left(\begin{array}{ccc} \gamma_u^+ & \sum_{j \neq y_i} & \partial \cos \theta_j \\ \end{array}\right) & \partial H_j $
m	0.35	(12)
	BUPT-Balancedface	BUPT-Globalface
Train	<ul> <li>Learning rate: 0.1         (20, 32, 36 epoch         에서 10으로 나눔)</li> <li>Epoch: 40</li> </ul>	<ul> <li>Learning rate: 0.1         (10, 18, 22 epoch에         서 10으로 나눔)</li> <li>Epoch: 24</li> </ul>

Embedding network	ResNet34, ResNet50, ResNet100 채택					
Framework	Pytorch	Pytorch				
Batch size	512	512				
S	64					
m	0.35					
	BUPT-Balancedface	BUPT-Globalface				
Train	<ul> <li>Learning rate: 0.1         (20, 32, 36 epoch         에서 10으로 나눔)</li> <li>Epoch: 40</li> </ul>	<ul> <li>Learning rate: 0.1         (10, 18, 22 epoch에         서 10으로 나눔)</li> <li>Epoch: 24</li> </ul>				

### 04-2. Ablation Study

- Effect of the overall FPR  $\gamma_u^+$ 
  - $\gamma_u^+ = 10^{-4}$  에서 최상의 성능 달성  $(\gamma_u^+ = 10^{-5}$  에서 백인의 높은 정확도를 제외)

Table 1. Verification performance (%) of different FPR parameter  $\gamma$ .

Methods (%)	African	Asian	Caucasian	Indian	Avg	Std
$\gamma_{}^{+} = 10^{-5}$	95.60	95.10	97.18	96.32	96.05	0.91
$\gamma_{u}^{+} = 10^{-4}$	95.95	95.17	96.78	96.38	96.07	0.69
$\gamma_u^+ = 10^{-3}$	95.47	94.90	96.92	96.12	95.84	0.87
$\gamma_u^+ = 10^{-2}$	95.45	94.78	96.98	96.13	95.84	0.94
$\gamma_u^{+} = 10^{-1}$	95.23	94.60	95.87	95.97	95.42	0.64

#### 04-2. Ablation Study

- Effect of exponent p in F(z)
  - 고정 FPR = 10<sup>-4</sup>로 설정
  - $F(z) = z^p$ 에서 p 효과 조사
  - p=2가 적당

Table 2. Verification performance (%) of different exponent p in F(z).

Methods (%)	African	Asian	Caucasian	Indian	Avg	Std
p = 0.25	95.35	95.10	96.97	96.07	95.87	0.84
p = 0.5	95.27	94.93	96.58	96.02	95.70	0.74
p = 1.0	95.18	94.92	96.90	95.83	95.71	0.88
p = 1.5	95.27	94.67	97.05	96.23	95.80	1.05
p = 2.0	95.95	95.17	96.78	96.38	96.07	0.69
p = 2.5	95.85	95.00	96.96	96.20	96.00	0.82
p = 3.0	95.60	95.18	97.17	95.98	95.98	0.85

- Accuracy on RFW
  - ResNet34 모델 사용
  - BUPT-Balancedface dataset 사용
  - SOTA에 비해 평균 정확도 약 0.77% 향상
  - SOTA에 비해 표준편차 0.69로 감소
  - ResNet50, 100에서도 비교적 좋은 성능
  - → 정확도 및 표준 편차를 통해 인종 균형/불균형 dataset에서 좋은 성능 달성

Table 3. Verification performance (%) of protocol on RFW with SOTA methods ([BUPT-Balancedface]).

Methods (%)	African	Asian	Caucasian	Indian	Avg	Std
ArcFace-R34 [18]	93.98	93.72	96.18	94.67	94.64	1.11
CosFace-R34 [18]	92.93	92.98	95.12	93.93	93.74	1.03
DebFace-R34 (ECCV'20)	93.67	94.33	95.95	94.78	94.68	0.83
PFE-R34 [5]	95.17	94.27	96.38	94.60	95.11	0.93
GAC-R34 [5]	94.65	94.93	96.23	95.12	95.23	0.60
RL-RBN-R34(cos) (CVPR'20)	95.27	94.52	95.47	95.15	95.10	0.41
RL-RBN-R34(arc) (CVPR'20)	95.00	94.82	96.27	94.68	95.19	0.93
Ours-R34	95.95	95.17	96.78	96.38	96.07	0.69
ArcFace-R50	95.55	94.95	96.68	95.47	95.66	0.73
Ours-R50	96.47	95.75	97.08	96.77	96.52	0.57
ArcFace-R100	96.43	94.98	97.37	96.17	96.24	0.98
Ours-R100	97.03	<b>95.65</b>	97.6	<b>96.82</b>	96.78	0.82

- Accuracy on RFW
  - ResNet34 모델 사용
  - BUPT-Globalface dataset 사용
  - ResNet50, 100에서도 비교적 좋은 성능
  - → 정확도 및 표준 편차를 통해 인종 균형/불균형 dataset에서 좋은 성능 달성

Table 4. Verification accuracy (%) of protocol on RFW with SOTA methods ([BUPT-Globalface]).

Methods (%)	African	Asian	Caucasian	Indian	Avg	Std
ArcFace-R34 [18]	93.87	94.55	97.37	95.86	95.37	1.53
CosFace-R34 [18]	92.17	93.50	96.63	94.68	94.25	1.90
RL-RBN-R34(cos) (CVPR'20)	94.27	94.58	96.03	95.15	95.01	0.77
RL-RBN-R34(arc) (CVPR'20)	94.87	95.57	97.08	95.63	95.79	0.93
Ours-R34	95.77	95.85	97.92	96.70	96.56	0.75
ArcFace-R50	96.23	96.43	97.98	96.92	96.89	0.78
Ours-R50	96.85	96.75	98.30	96.95	97.21	0.73
ArcFace-R100	96.68	96.10	98.17	97.32	97.07	0.89
Ours-R100	97.37	96.48	98.57	97.4	97.45	0.85

- SOTA methods와 Bias degree 비교
  - 전체 FPR에 따라 편향 비교
  - 본 논문에 제시한 방법의 편향이 모든 FPR에 있어서 훨씬 낮음

Table 5. Bias degree of protocol on RFW with SOTA methods.

overall FPR	$10^{-5}$	$10^{-4}$	$10^{-3}$	$10^{-2}$
RL-RBN-R34(arc)	351.98	208.44	92.18	16.70
Ours-R34	257.53	185.91	<b>59.25</b>	10.33

Table 6. Bias degree of protocol on BFW with SOTA methods.

overall FPR	$10^{-7}$	$10^{-6}$	$10^{-5}$	$10^{-4}$	$10^{-3}$
RL-RBN-R34(arc)	2.44	2.01	2.49	2.91	2.43
Ours-R34	1.18	1.08	1.18	1.67	1.80

- FPR on RFW
  - (a)에서 아프리카 ROC curve를 통해 높은 성능 확인
  - RFW에 대해 제안한 loss가 RL-RBN(arc)보다 더 좋은 성능임을 증명

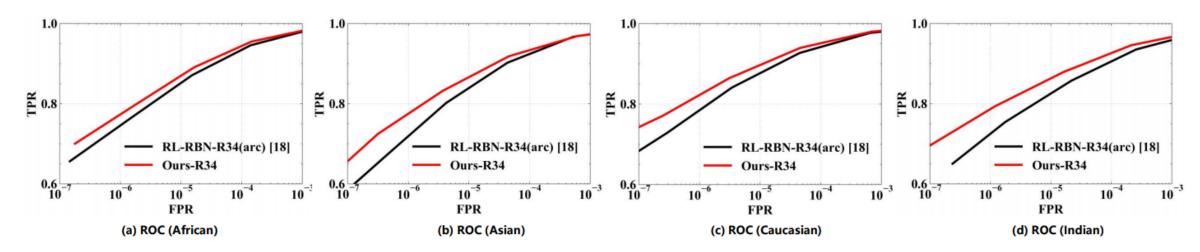
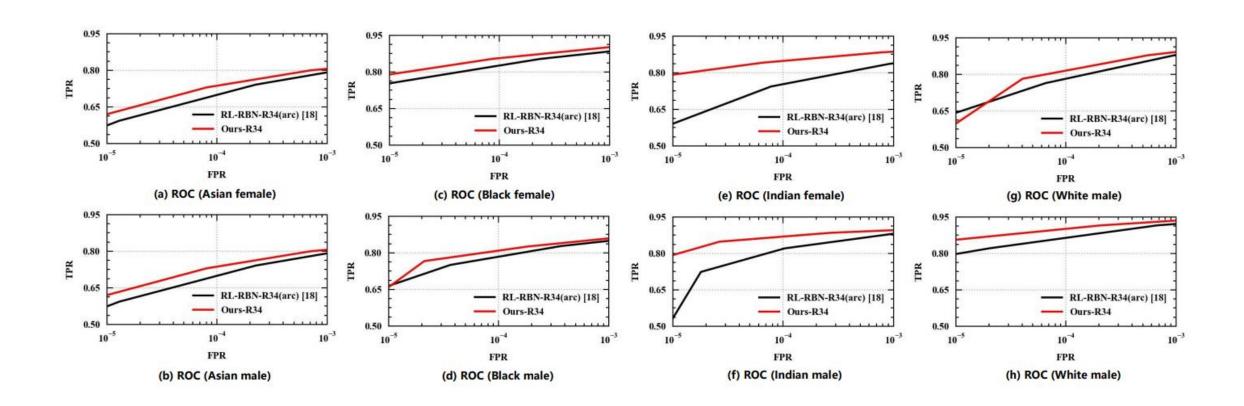


Figure 5. ROC for RFW.

- FPR on BFW
  - BFW의 8개의 모든 인구 통계학적 그룹에 대한 ROC curve
  - 모든 인종에 걸쳐 여성 그룹과 남성 그룹 모두 더 나은 성능 달성



#### 05. Conclusion

#### 05. Conclusion

1 얼굴 인식에서 편향 완화 및 공정성 향상

2 SOTA 경쟁사와 비교하여 제안한 방법의 효과 입증

향후 FP 사례로 인한 노이즈 샘플 영향 조사 등 다양한 측면으로 확장 가능